

Introdução  
oooooo

Fundamentação Teórica  
oooooooo

Metodologia  
oooooo

Desenvolvimento  
oooooooooooooooooooo

Conclusão  
oooo

# APLICAÇÃO DE MÉTODOS DE APRENDIZADO DE MÁQUINA PARA CLASSIFICAÇÃO DE IMAGENS DE SENSORIAMENTO REMOTO POR SATÉLITES

Alexandre de Tomy Silva

Outubro/2019

Introdução  
oooooo

Fundamentação Teórica  
oooooooo

Metodologia  
oooooo

Desenvolvimento  
oooooooooooooooooooo

Conclusão  
oooo

Introdução

•○○○○○

Fundamentação Teórica

○○○○○○○

Metodologia

○○○○○

## Desenvolvimento

A horizontal row of fifteen empty circles, evenly spaced, used as a visual element in a document.

Conclusão

○○○○

## Introdução

## Observação da Terra

- Dados gerados pela Observação da Terra
    - Visão multitemporal
    - Monitoramento dos recursos terrestres

## Sensoriamento Remoto

*Sensoriamento remoto é uma técnica de obtenção de imagens dos objetos da superfície terrestre sem que haja um contato físico de qualquer espécie entre o sensor e o objeto.*

- Coleta, distribuição e análise
- Mudanças na ocupação do solo afetam o clima

## Classificação de Imagens

- Aprendizado de máquina para reconhecimento de padrões de classes de uso e cobertura da terra
    - Não é necessário conhecimento a priori sobre distribuição dos dados
    - Base para outras aplicações

## Disponibilidade dos dados

- Demanda para processamento e armazenamento
  - Plataformas de computação em nuvem como solução
    - Monitoramento em escala global
    - Problemas de reproduzibilidade

# Objetivo

- Desenvolvimento e estudo de modelos preditivos de classificação de imagens de sensoriamento remoto
  - Dados: **MapBiomas** e **Sentinel-2/MSI**
  - Área de interesse: Região do município de **Bauru**
  - Ferramentas: Linguagem **R** e **Google Earth Engine**
  - Classes: padrões de **uso** e **cobertura terrestre**
  - Algoritmos: **Máquina de Vetores Suporte** (linear com regularização e com função de base radial como núcleo) e **Florestas Aleatórias**

Introdução  
oooooo

Fundamentação Teórica  
●oooooooo

Metodologia  
oooooo

Desenvolvimento  
oooooooooooooooooooo

Conclusão  
oooo

## Fundamentação Teórica

# Sensoriamento Remoto

- Presença de um **alvo** (superfície terrestre) que interage com a **energia** (radiação) provinda de uma **fonte** (luz solar), gerando uma resposta que é captada por um **sensor** (acoplado em um satélite).

# Aprendizado de máquina

- Aprendizado de Máquina é uma área da inteligência artificial que se refere ao desenvolvimento de métodos que otimizam sua performance iterativamente aprendendo com dados

# Aprendizado de máquina |

- Problema de **classificação** pixel a pixel, aplicando métodos **supervisionados e não paramétricos**

# Aprendizado de máquina | *Support Vector Machines*

- Achar o **limite de decisão** que separa as classes (binário)
- Projeção do espaço de características para uma dimensão maior
  - Funções de núcleo (polinomial, lineares, etc)

# Aprendizado de máquina | *Decision Trees*

- “Cortes” recursivos e repetidos
  - Cada corte gera um “tronco”
  - “Folhas” são as classes

# Aprendizado de máquina | *Random Forests*

- Conjunto de Árvores de Decisões
- Classe será definida pelo “voto” da maioria das árvores da floresta
  - Previne problema de **alto viés**
- Cada árvore é treinada com um único subconjunto de teste e variáveis
  - Uma árvore será menos precisa, porém, menos correlacionada com as outras

## Introdução

## Fundamentação Teórica

## Metodología

## Desenvolvimento



Conclusão

## Metodologia

## Dados | MapBiomas

*O projeto MapBiomas é uma iniciativa multi-institucional para gerar mapas anuais de cobertura e uso do solo a partir de processos de classificação automática aplicada a imagens de satélite.*

# Dados | Sentinel-2/MSI

- Programa Sentinel
  - Resolução espacial média (10-30m)
  - Sensor multiespectral
  - Dados abertos desde 2013

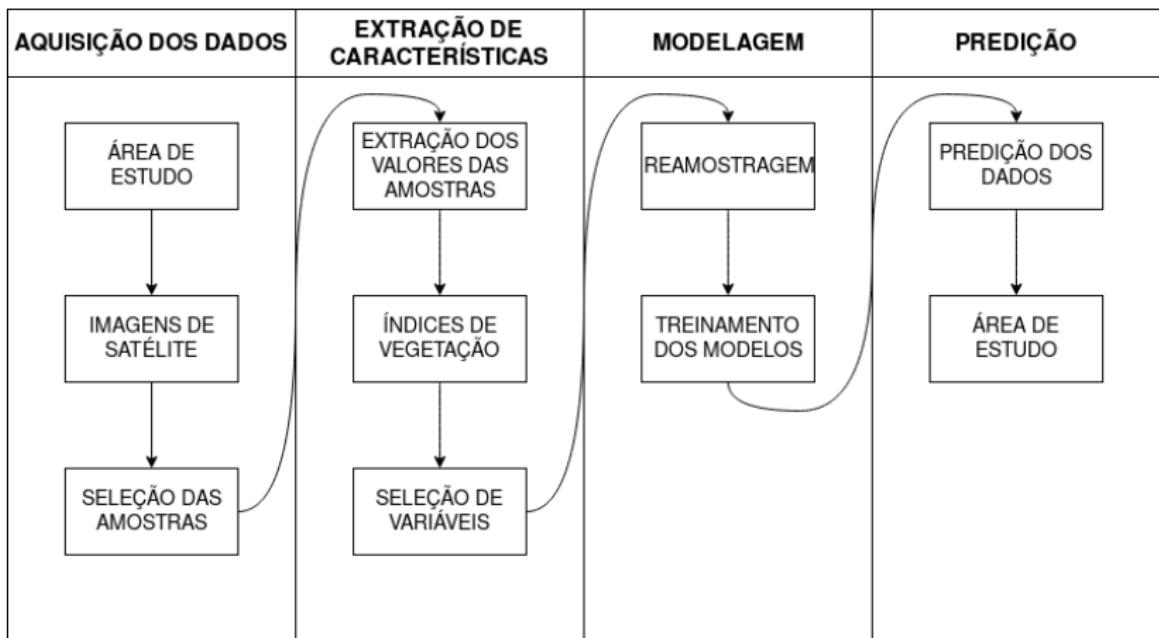
# Ambientes | R

- Linguagem de paradigmas funcional e orientado a objeto
- Muito utilizada para análises estatísticas
- Ambiente integrado com bibliotecas de dados geoespaciais
- Forte documentação

## Ambientes | *Google Earth Engine*

- Ambiente de computação em núvem
- Diversas coleções de dados de satélite
- Processamento extremamente rápido
- Utilizado pelo MapBiomas

# Etapas



Introdução  
oooooo

Fundamentação Teórica  
oooooooo

Metodologia  
oooooo

Desenvolvimento  
●oooooooooooooooooooo

Conclusão  
oooo

## Desenvolvimento

# Aquisicao dos Dados | Satélite Sentinel-2

banda	nome	lambda	resolucao
B1	Aerosol	0.443	60
B2	Azul	0.490	10
B3	Verde	0.560	10
B4	Vermelho	0.665	10
B8	NIR	0.842	10
B5	Red edge 1	0.705	20
B6	Red edge 2	0.740	20
B7	Red edge 3	0.783	20
B9	Vapor d'água	0.940	60
B10	Cirrus	1.375	60
B11	SWIR 1	1.610	20
B12	SWIR 2	2.190	20
B8A	Red edge 4	0.865	20

Introdução  
oooooo

Fundamentação Teórica  
oooooooo

Metodologia  
oooooo

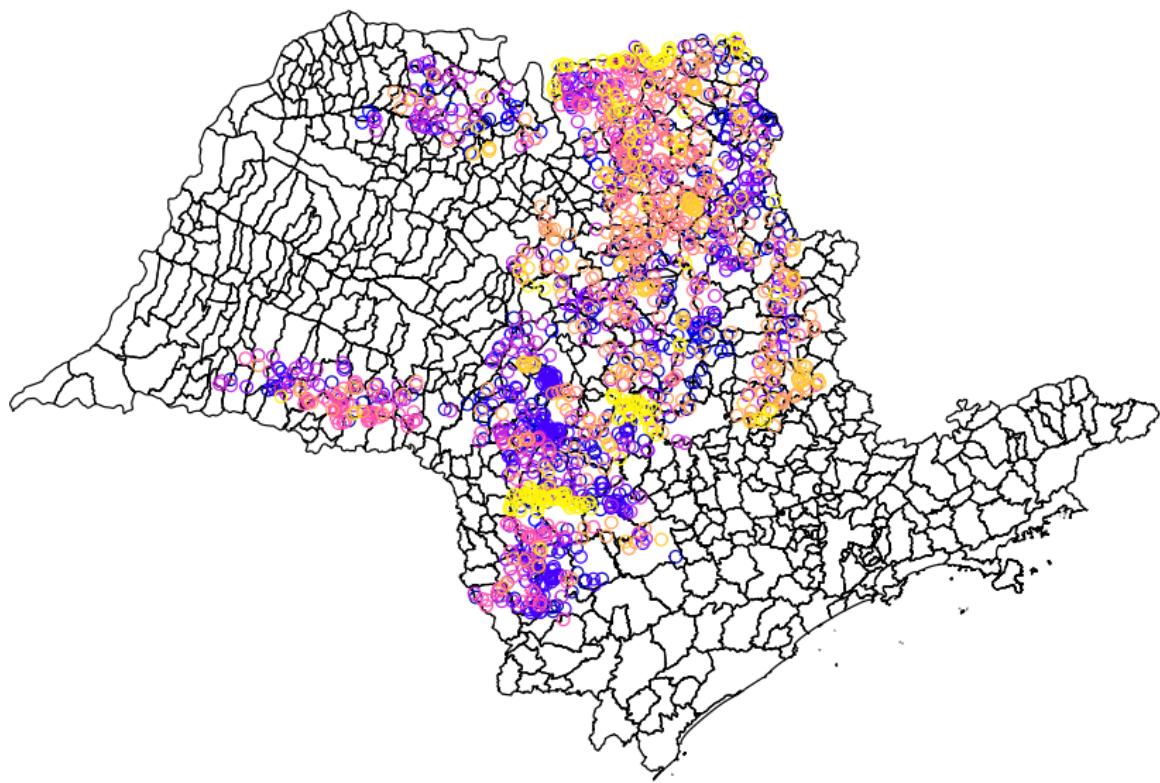
Desenvolvimento  
○○●oooooooooooooooooooo

Conclusão  
oooo

## Aquisição dos dados | Satélite Sentinel-2



## Aquisição dos dados | Seleção das amostras



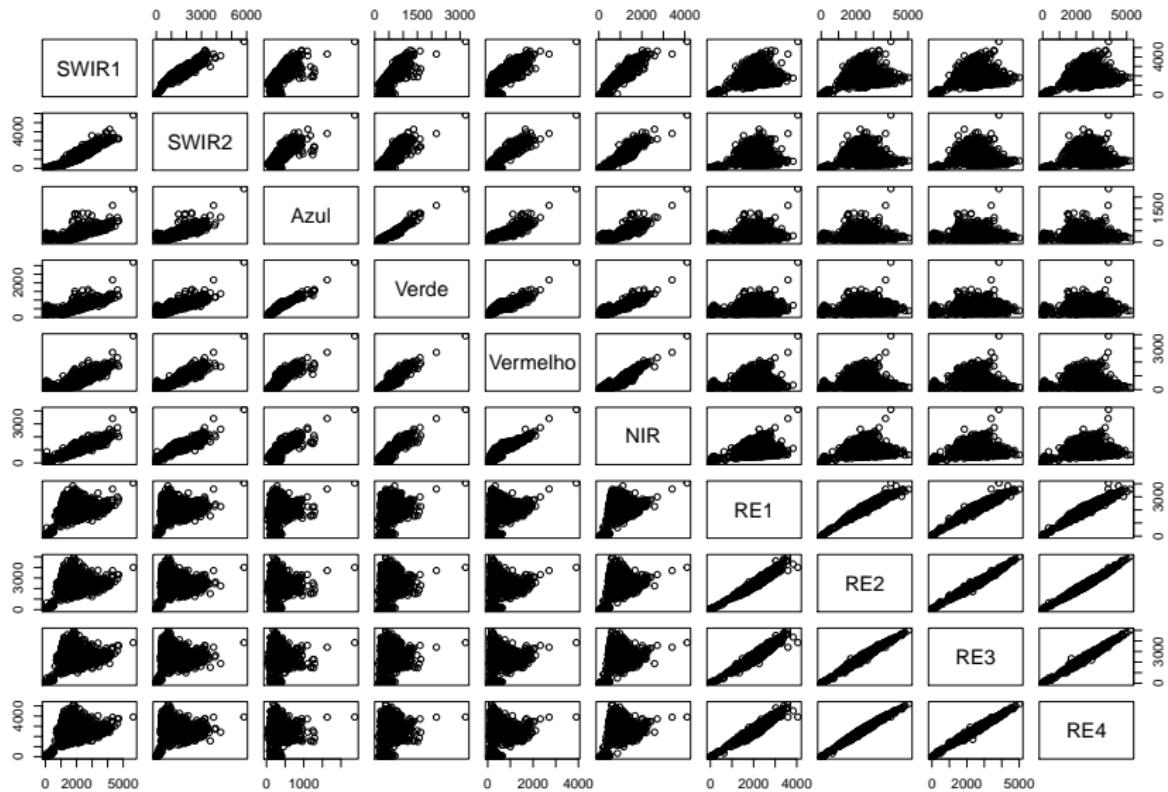
# Aquisição dos dados | Seleção das amostras

Var1	Freq
3	200
4	91
9	200
12	140
15	200
19	146
20	200
21	200
24	108
33	161

## Extracao de características | Indice de vegetacao



# Extracao de características | Seleção das bandas



# Reamostragem

Table 1: Amostras para treino

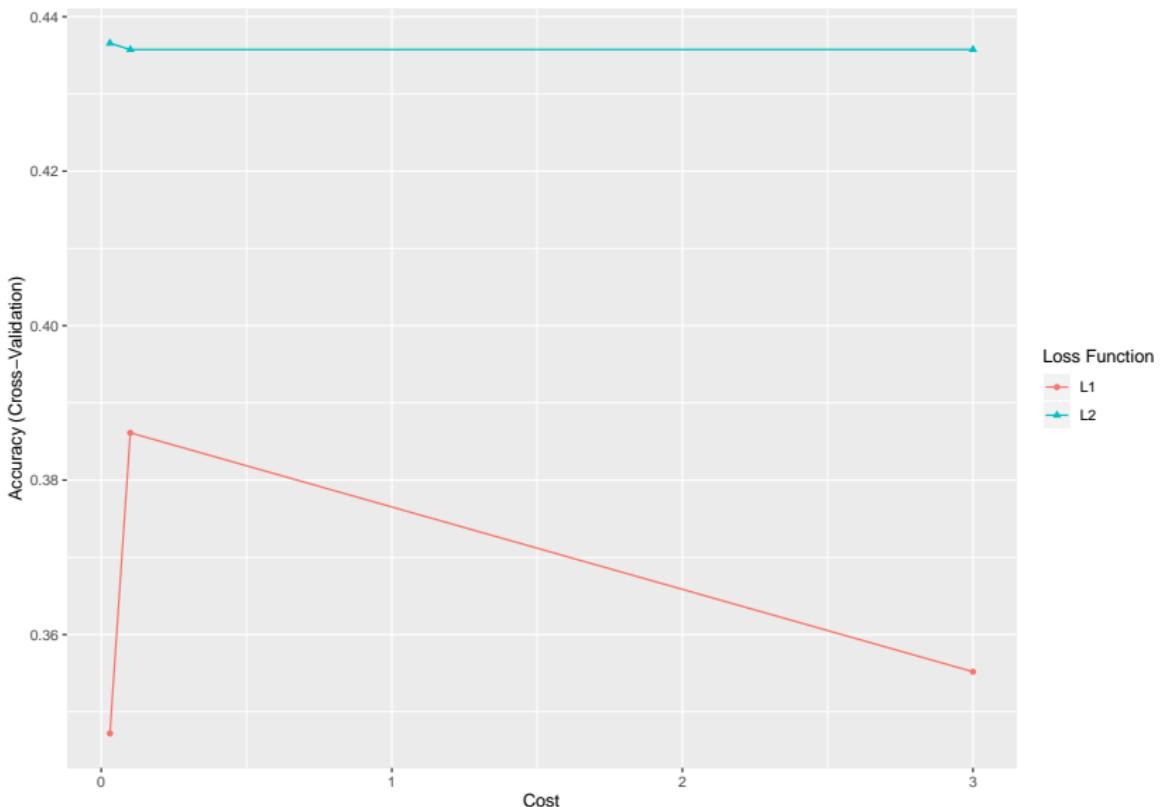
Var1	Freq
agricultura_pastagem	148
cultura_anual_perene	110
cultura_semi_perene	150
floresta_plantada	150
formacao_campestre	105
formacao_florestal	150
formacao_savanica	69
infra_urbana	79
pastagem	149
rio_lago_oceano	120

# Reamostragem

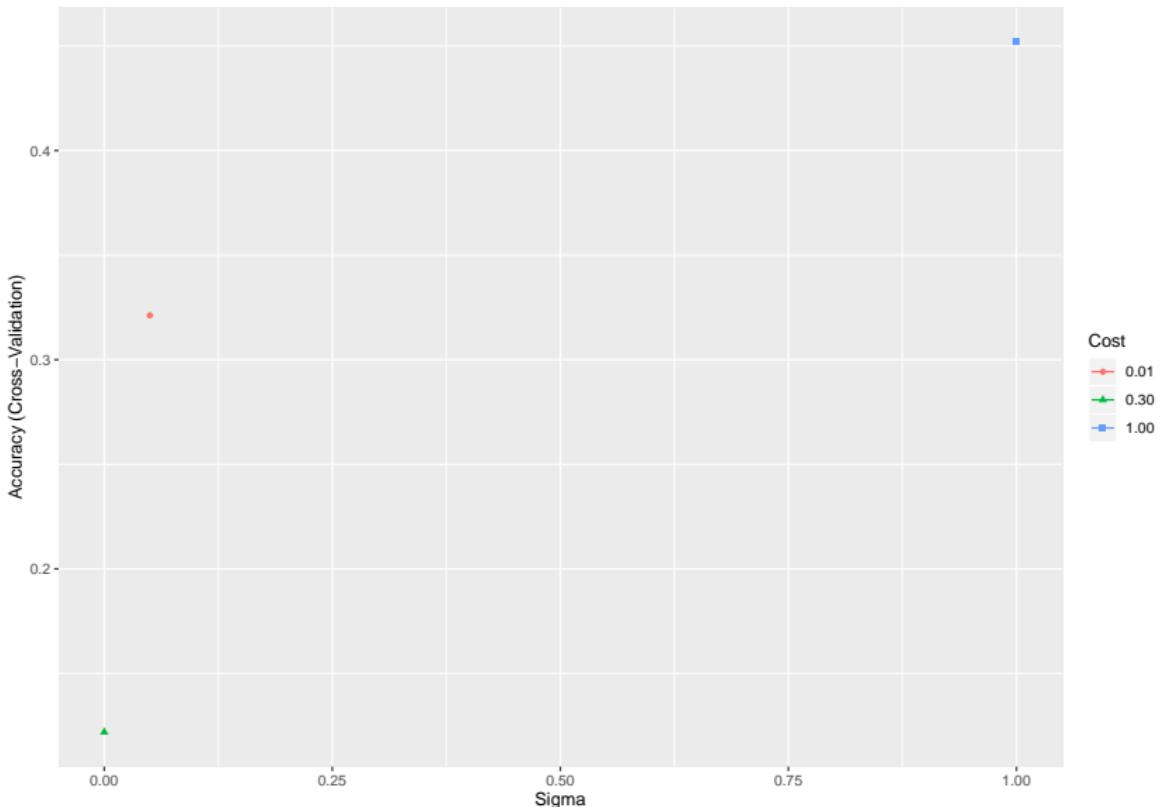
Table 2: Amostras para teste

Var1	Freq
agricultura_pastagem	49
cultura_anual_perene	36
cultura_semi_perene	50
floresta_plantada	50
formacao_campestre	35
formacao_florestal	49
formacao_savanica	22
infra_urbana	26
pastagem	49
rio_lago_oceano	39

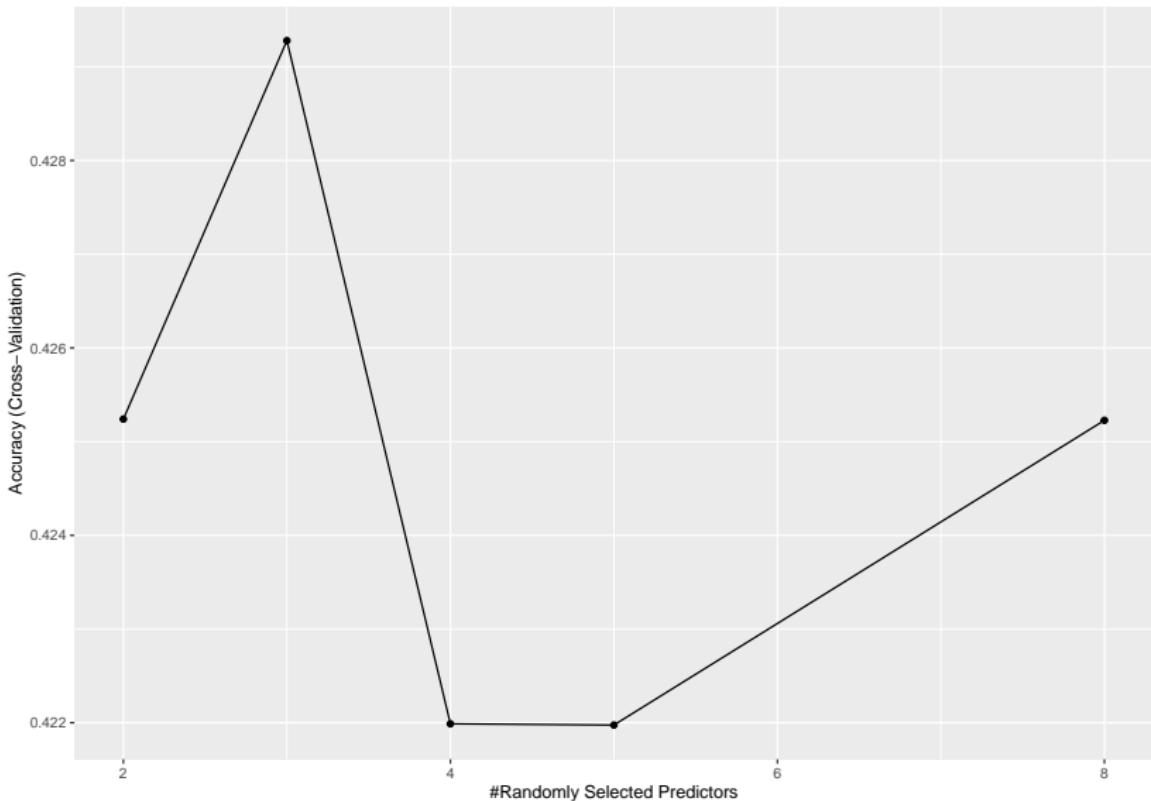
## Treinamento | SVM Linear



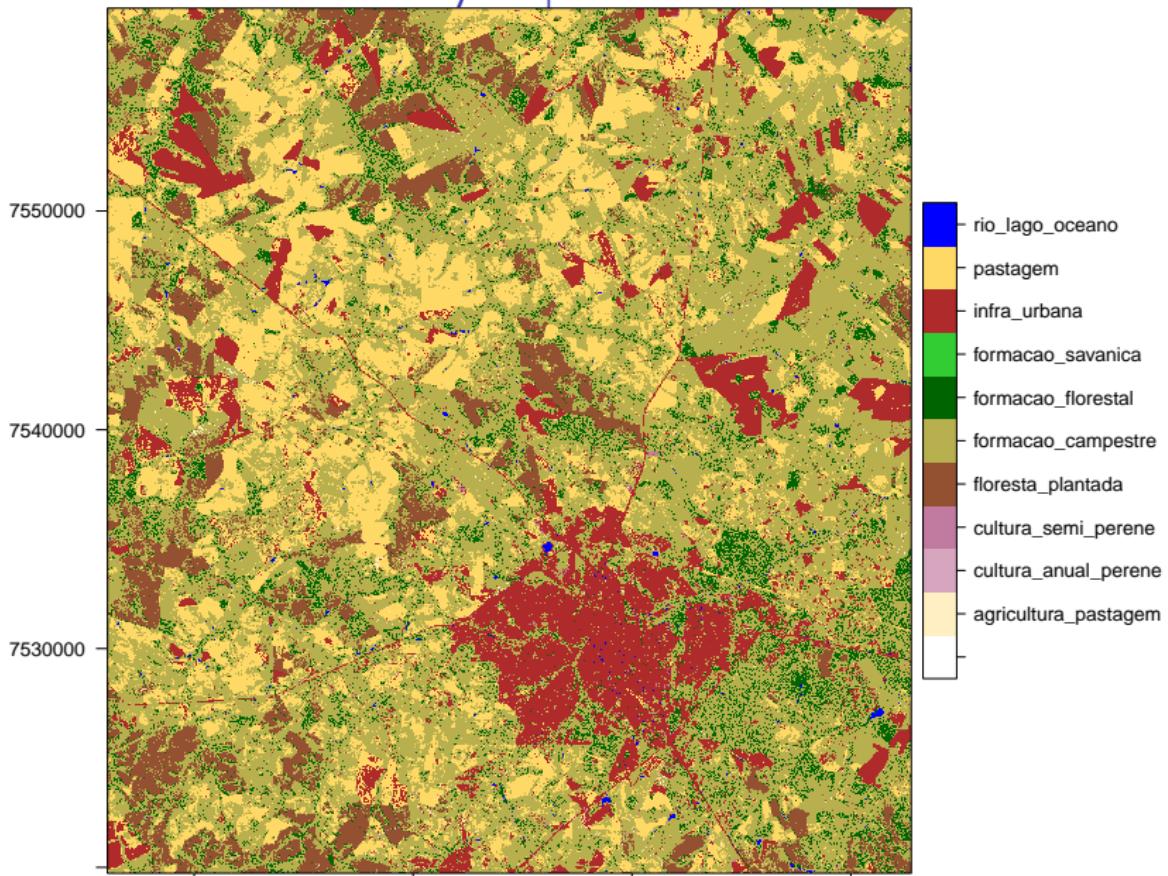
# Treinamento | SVM Radial



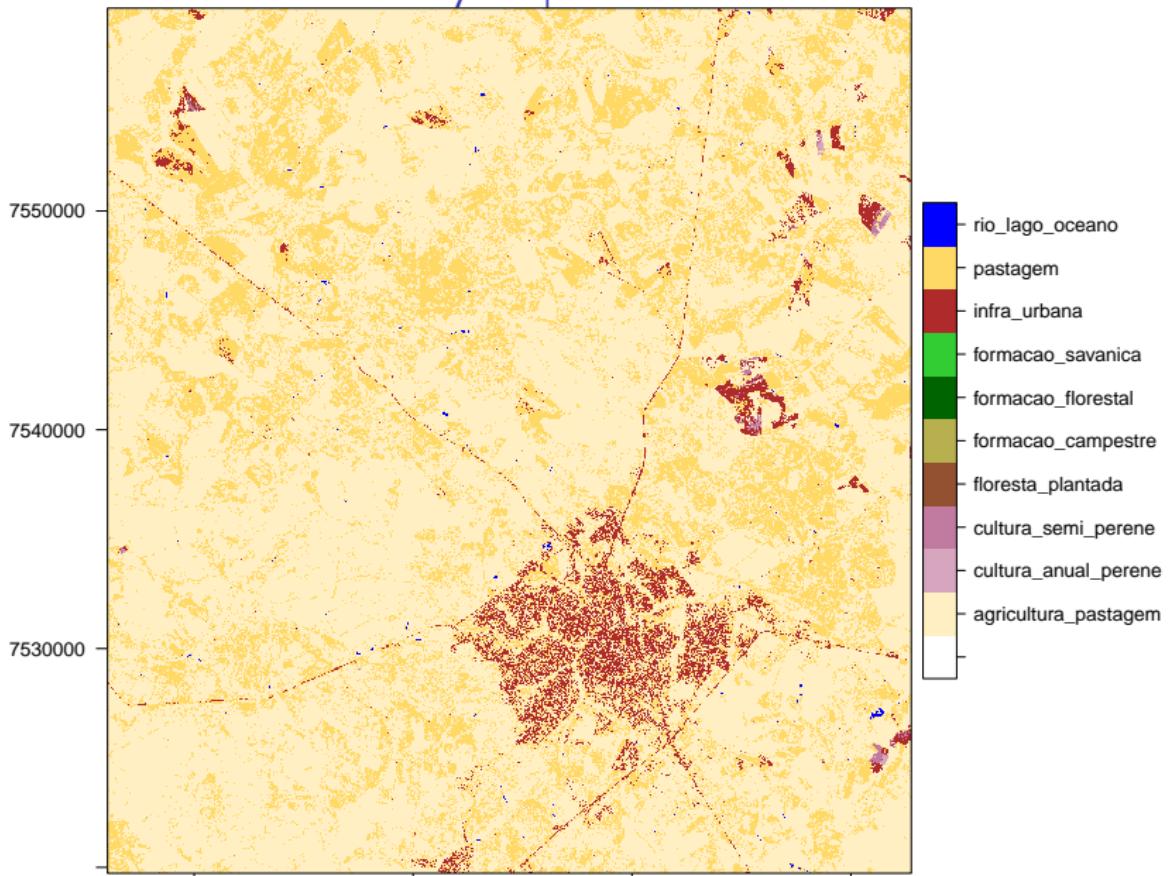
## Treinamento | Random Forests



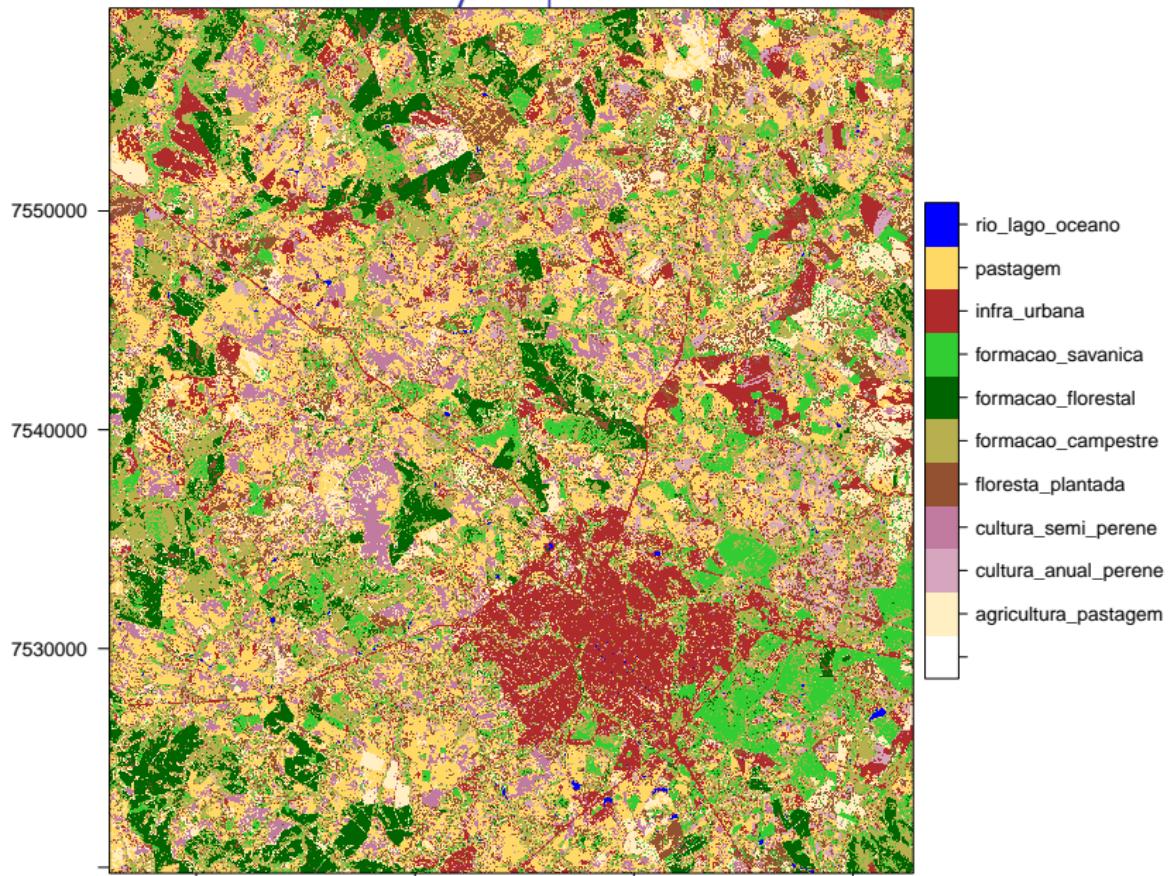
## Predição | SVM Linear



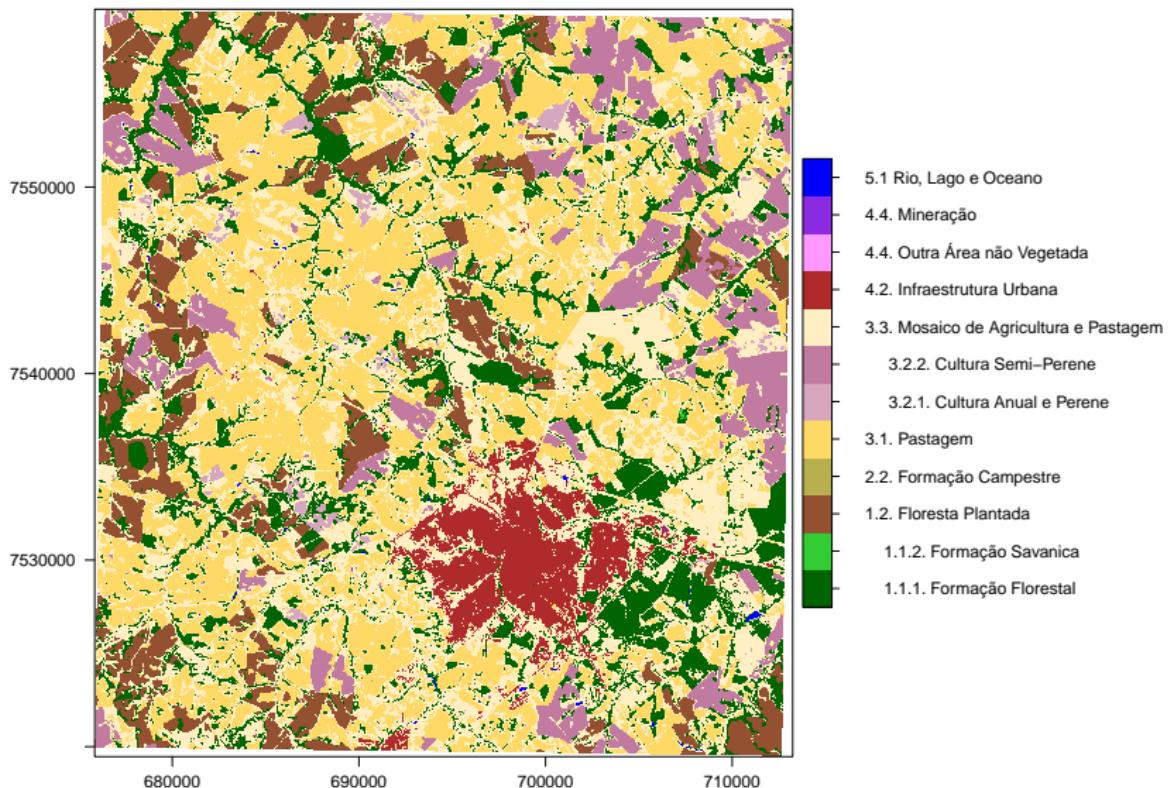
## Predição | SVM Radial



## Predição | SVM Radial



# Mapa de referência | Mapbiomas



## Avaliação de precisão

- Matriz de erro para cada modelo com 100 pontos de amostras de cada classe extraídos do *raster* do MapBiomas

Modelo	Kappa	Acuracia
MVS linear	0.2992465	0.3772321
MVS radial	0.2684340	0.3882353
Florestas Aleatorias	0.1316405	0.2284434

## Considerações

- Classes que sofreram confusão (ex: formacao\_florestal e floresta\_plantada)
  - Variáveis preditoras insuficientes
- Classes predominantes na classsificação com MVS radial

Introdução  
oooooooo

Fundamentação Teórica  
ooooooooo

Metodologia  
ooooooo

Desenvolvimento  
oooooooooooooooooooo

Conclusão  
●○○○

## Conclusão

## Conclusão

- Sistemas de Sensoriamento Remoto que permitem imageamento da superfície terrestre
- Um modelo preditivo bem ajustado depende de uma série de considerações a serem avaliadas
- Aplicações: Monitoramento de recursos; análises temporais; planejamento urbano; cruzamento de dados; entre outras aplicações
- Trabalhos futuros: comparação com outra base de dados; seleção de amostras de outras regiões; etapas adicionais de pré processamento e extração de características; utilização de outros algoritmos como Redes Neurais Artificiais

## Introdução

## Fundamentação Teórica

## Metodología

Desenvolvimento  
oooooooooooooooooooo

Conclusão  
●○○

Dúvidas?

Introdução  
oooooo

Fundamentação Teórica  
oooooooo

Metodologia  
oooooo

Desenvolvimento  
oooooooooooooooooooo

Conclusão  
ooo●

Obrigado!